

# Sistematização — Matemática e Estatística para Computação

Laboratório Estatístico Interativo

Entrega do **Grupo Sigma** · Prof. Romes

## 1. Identificação

| Nome completo        | Matrícula |
|----------------------|-----------|
| Gustavo Santana      | 72650214  |
| Pedro Oliveira Rocha | 72650213  |
| Pedro Falcão         | 72650212  |

**Nome do grupo:** Grupo Sigma

## 2. Link dos dados crus

**Fonte original:** <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>

Bike Sharing Dataset — UCI Machine Learning Repository. Arquivo `hour.csv`: 17.379 registros horários (2011–2012) do sistema Capital Bikeshare, Washington D.C., com condições climáticas, calendário e contagem de aluguéis.

## 3. Link da solução

**Repositório público:** <https://github.com/santanexx/sistematizacao-matematica>

Contém o código-fonte completo (núcleo estatístico separado da interface), o arquivo de testes automatizados, o `README.md` com os nomes dos componentes e instruções de execução, e o `RELATORIO.md` da atividade. Histórico com 31 commits assinados, distribuídos entre os três integrantes.

## 4. Link do vídeo de demonstração

**Vídeo (3–5 min):** [\[link a ser inserido antes do envio\]](#)

Links testados em janela anônima antes do envio. Repositório público; dataset em fonte aberta.

## 5. Resumo executivo

Grupo Sigma · Gustavo Santana (72650214) · Pedro Oliveira Rocha (72650213) · Pedro Falcão (72650212)

### O que foi construído

Uma aplicação Streamlit em que **nenhuma medida exibida ao usuário vem de biblioteca pronta**. O pacote próprio `minhastats/` implementa todo o núcleo estatístico em Python puro — importando apenas `math` e `random` — e é validado contra NumPy, SciPy e `statistics` por **521 testes automatizados**, com tolerância relativa de  $10^{-9}$  justificada pela análise de erro de ponto flutuante. Até os gráficos respeitam a regra: histograma via `ax.bar` sobre a nossa tabela de classes e boxplot via `ax.bxp` com os nossos quartis, porque `plt.hist` e `plt.boxplot` calculariam eles mesmos.

### Dataset

Bike Sharing Dataset (UCI): 17.379 registros, 10 variáveis numéricas e 7 categóricas na aplicação. As variáveis meteorológicas, normalizadas no original, foram convertidas para °C, % e km/h pela transformação inversa documentada pelos autores.

### Módulos implementados

| Módulo             | Entregue                                                                                                                                                                                                                                                                                           |
|--------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 0 — Dados reais    | Dataset, conferência automática dos requisitos, dicionário de variáveis.                                                                                                                                                                                                                           |
| 1 — Núcleo próprio | Biblioteca <code>minhastats/</code> em Python puro: média, mediana, moda, amplitude, variância e desvio padrão (amostral e populacional), percentis, quartis, IQR, CV, covariância, Pearson, assimetria e curtose. Página própria na aplicação com fórmulas, código-fonte e execução da validação. |
| 2 — Descritiva     | Tabelas de frequência, medidas, histograma, boxplot, barras, pizza, outliers por IQR e interpretação textual automática.                                                                                                                                                                           |
| 3 — Simulação      | Lei dos Grandes Números (moeda, dado, $\pi$ ) e Teorema Central do Limite, com repetições, tamanho da amostra e semente controlados pelo usuário.                                                                                                                                                  |
| 4 — Distribuições  | Normal, Uniforme, Exponencial, Poisson e Binomial sobrepostas ao histograma, parâmetros estimados dos dados, $\chi^2$ comparativo.                                                                                                                                                                 |
| 5 — Regressão      | Dispersão, $r$ , mínimos quadrados próprios, equação, $R^2$ , predição interativa com alerta de extrapolação, resíduos e alerta de causalidade.                                                                                                                                                    |
| 6 — Descobertas    | As três descobertas abaixo, recalculadas ao vivo pelo núcleo.                                                                                                                                                                                                                                      |

### As três principais descobertas

#### 1. A temperatura importa — mas explica menos de 17% dos aluguéis.

$r = 0,4048$  e reta  $\hat{y} = 9,30x - 0,04$  (cada  $+1$  °C  $\Rightarrow +9,3$  aluguéis/hora). Mas  $R^2 = 0,1638$ : 83,6% da variação ficam de fora — não por falta de relação, e sim porque a relação não é linear. A demanda tem dois picos diários (359 aluguéis às 8h, 461 às 17h, contra 6,35 às 4h) que nenhuma reta em função da temperatura captura. O gráfico de resíduos mostra um funil (heterocedasticidade).

#### 2. Dois públicos opostos escondidos no mesmo total.

Do dia útil para o fim de semana, usuários casuais sobem  $+124,7\%$  ( $25,6 \rightarrow 57,4$  aluguéis/h) enquanto registrados caem  $-26,1\%$  ( $167,7 \rightarrow 124,0$ ). No agregado os efeitos quase se cancelam ( $-6,1\%$ ): olhar só o total levaria à conclusão errada de que o calendário não afeta a demanda. É o paradoxo da agregação — lazer contra deslocamento pendular. CV de 138% contra 98%, curtose 7,57 contra 2,75 e 1.192 outliers no público casual.

#### 3. Os dados violam a Poisson por um fator de 174× — e o TCL não se abala.

Aluguéis são contagens, mas o índice de dispersão  $s^2/\bar{x}$  vale 173,66 (na Poisson vale 1): sobredispersão extrema, modelo descartado. Ainda assim, partindo de uma variável com assimetria 2,499 e curtose 7,569, o TCL funciona como prometido: a assimetria das médias amostrais cai para 0,132 com  $n = 200$  ( $-94,7\%$ ) e o desvio observado reproduz  $\sigma/\sqrt{n}$  com erro inferior a 2% em todos os tamanhos testados.

### Reprodutibilidade

```
git clone https://github.com/santanexx/sistematizacao-matematica.git && cd sistematizacao-matematica
python3 -m venv .venv && source .venv/bin/activate && pip install -r requirements.txt
pytest # 521 testes      ·      streamlit run app.py
```

Sementes fixas (42, 2024, 21) tornam todos os números acima reproduzíveis em qualquer máquina.