

Sistematização — Matemática e Estatística para Computação

Laboratório Estatístico Interativo

Entrega do **Grupo Sigma** · Prof. Romes

1. Identificação

Nome completo	Matrícula
Gustavo Santana	72650214
Pedro Oliveira Rocha	72650213
Pedro Falcão	72650212

Nome do grupo: Grupo Sigma

2. Link dos dados crus

Fonte original: <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>

Bike Sharing Dataset — UCI Machine Learning Repository. Arquivo `hour.csv`: 17.379 registros horários (2011–2012) do sistema Capital Bikeshare, Washington D.C., com condições climáticas, calendário e contagem de aluguéis.

3. Link da solução

Repositório público: <https://github.com/santanexx/sistematizacao-matematica>

Contém o código-fonte completo (núcleo estatístico separado da interface), o arquivo de testes automatizados, o `README.md` com os nomes dos componentes e instruções de execução, e o `RELATORIO.md` da atividade. Histórico com 31 commits assinados, distribuídos entre os três integrantes.

4. Link do vídeo de demonstração

Vídeo (3–5 min): [\[link a ser inserido antes do envio\]](#)

Links testados em janela anônima antes do envio. Repositório público; dataset em fonte aberta.

5. Resumo executivo

Grupo Sigma · Gustavo Santana (72650214) · Pedro Oliveira Rocha (72650213) · Pedro Falcão (72650212)

O que foi construído

Uma aplicação Streamlit em que **nenhuma medida exibida ao usuário vem de biblioteca pronta**. O pacote próprio `minhastats/` implementa todo o núcleo estatístico em Python puro — importando apenas `math` e `random` — e é validado contra NumPy, SciPy e `statistics` por **518 testes automatizados**, com tolerância relativa de 10^{-9} justificada pela análise de erro de ponto flutuante. Até os gráficos respeitam a regra: histograma via `ax.bar` sobre a nossa tabela de classes e boxplot via `ax.bxp` com os nossos quartis, porque `plt.hist` e `plt.boxplot` calculariam eles mesmos.

Dataset

Bike Sharing Dataset (UCI): 17.379 registros, 10 variáveis numéricas e 7 categóricas na aplicação. As variáveis meteorológicas, normalizadas no original, foram convertidas para °C, % e km/h pela transformação inversa documentada pelos autores.

Módulos implementados

Módulo	Entregue
0 — Dados reais	Dataset, conferência automática dos requisitos, dicionário de variáveis.
1 — Núcleo próprio	Média, mediana, moda, amplitude, variância e desvio padrão (amostral e populacional), percentis, quartis, IQR, CV, covariância, Pearson, assimetria e curtose — todos testados contra NumPy/SciPy.
2 — Descritiva	Tabelas de frequência, medidas, histograma, boxplot, barras, pizza, outliers por IQR e interpretação textual automática.
3 — Simulação	Lei dos Grandes Números (moeda, dado, π) e Teorema Central do Limite, com repetições, tamanho da amostra e semente controlados pelo usuário.
4 — Distribuições	Normal, Uniforme, Exponencial, Poisson e Binomial sobrepostas ao histograma, parâmetros estimados dos dados, χ^2 comparativo.
5 — Regressão	Dispersão, r , mínimos quadrados próprios, equação, R^2 , predição interativa com alerta de extrapolação, resíduos e alerta de causalidade.
6 — Descobertas	As três descobertas abaixo, recalculadas ao vivo pelo núcleo.

As três principais descobertas

1. A temperatura importa — mas explica menos de 17% dos aluguéis.

$r = 0,4048$ e reta $\hat{y} = 9,30x - 0,04$ (cada $+1\text{ °C} \Rightarrow +9,3$ aluguéis/hora). Mas $R^2 = 0,1638$: 83,6% da variação ficam de fora — não por falta de relação, e sim porque a relação não é linear. A demanda tem dois picos diários (359 aluguéis às 8h, 461 às 17h, contra 6,35 às 4h) que nenhuma reta em função da temperatura captura. O gráfico de resíduos mostra um funil (heterocedasticidade).

2. Dois públicos opostos escondidos no mesmo total.

Do dia útil para o fim de semana, usuários casuais sobem $+124,7\%$ ($25,6 \rightarrow 57,4$ aluguéis/h) enquanto registrados caem $-26,1\%$ ($167,7 \rightarrow 124,0$). No agregado os efeitos quase se cancelam ($-6,1\%$): olhar só o total levaria à conclusão errada de que o calendário não afeta a demanda. É o paradoxo da agregação — lazer contra deslocamento pendular. CV de 138% contra 98%, curtose 7,57 contra 2,75 e 1.192 outliers no público casual.

3. Os dados violam a Poisson por um fator de 174× — e o TCL não se abala.

Aluguéis são contagens, mas o índice de dispersão $s^2/\bar{x}$ vale 173,66 (na Poisson vale 1): sobredispersão extrema, modelo descartado. Ainda assim, partindo de uma variável com assimetria 2,499 e curtose 7,569, o TCL funciona como prometido: a assimetria das médias amostrais cai para 0,132 com $n = 200$ ($-94,7\%$) e o desvio observado reproduz $\sigma/\sqrt{n}$ com erro inferior a 2% em todos os tamanhos testados.

Reprodutibilidade

```
git clone https://github.com/santanexx/sistematizacao-matematica.git && cd sistematizacao-matematica
python3 -m venv .venv && source .venv/bin/activate && pip install -r requirements.txt
pytest # 518 testes      ·      streamlit run app.py
```

Sementes fixas (42, 2024, 21) tornam todos os números acima reproduzíveis em qualquer máquina.